

AMLGuardian

Guia completa del proyecto de portfolio

Deteccion de blanqueo de capitales con SQL, dbt, Neo4j, XGBoost y Power BI

Proyecto	AMLGuardian — Financial Crime Detection System
Autor	Diego Sanchez Peinado
Dataset	IBM AML Synthetic Transactions (10M+ filas)
Stack	PostgreSQL · dbt · Airflow · Neo4j · XGBoost · Power BI · Docker
Objetivo	Portfolio AML/FinCrime Analytics — Madrid/Dublin 2026-2028

Indice de contenidos

1. Que es AML y por que importa

- 1.1 El blanqueo de capitales explicado
- 1.2 La regulacion que obliga a los bancos
- 1.3 Por que hay tan pocos analistas AML

2. Arquitectura del sistema

- 2.1 Vision general: como fluyen los datos
- 2.2 Cada pieza del puzzle explicada
- 2.3 Por que este stack y no otro

3. El dataset: los datos de partida

- 3.1 Que contiene el dataset de IBM
- 3.2 Estructura de transacciones y cuentas
- 3.3 Como se carga en el sistema

4. Deteccion de tipologias AML con SQL

- 4.1 Smurfing
- 4.2 Fan-out
- 4.3 Fan-in
- 4.4 Circular
- 4.5 Layering
- 4.6 Alta exposicion geografica

5. El modelo de datos con dbt

- 5.1 Que es dbt
- 5.2 Staging
- 5.3 Feature mart
- 5.4 Alert mart
- 5.5 SAR candidates
- 5.6 Tests de calidad

6. Analisis de redes con Neo4j

- 6.1 Por que los grafos
- 6.2 Como se construye el grafo
- 6.3 PageRank
- 6.4 Louvain

7. El modelo de machine learning

- 7.1 Para que sirve el scoring
- 7.2 Features de entrada
- 7.3 SMOTE
- 7.4 XGBoost vs LightGBM
- 7.5 SHAP

8. Orquestacion con Airflow

8.1 Que es un DAG

8.2 El pipeline de AMLGuardian

9. Tu trabajo como analista

9.1 Investigation queries SQL

9.2 Dashboard Power BI

9.3 Documentacion SAR

10. Como explicarlo en entrevistas

1 Que es AML y por que importa

1.1 El blanqueo de capitales explicado

Imagina que has robado un millon de euros. No puedes simplemente depositarlo en el banco, porque el banco te preguntaria de donde viene. Necesitas hacer que ese dinero parezca legal. Eso es el blanqueo de capitales: el proceso de darle apariencia legitima a dinero que proviene de actividades ilegales.

El proceso tiene tres fases classicas que cualquier analista AML debe conocer:

Fase	Nombre	Que pasa	Ejemplo real
1	Placement (Colocacion)	El dinero ilegal entra al sistema financiero	Depositar efectivo en pequenas cantidades para no levantar sospechas
2	Layering (Estratificacion)	Se crean capas de transacciones para ocultar el origen	Transferir dinero en muchas cuentas en distintos paises, cambiar divisas
3	Integration (Integracion)	El dinero 'limpio' vuelve a la economia	Comprar inmuebles, empresas o bienes de lujo con el dinero

Las tres fases del blanqueo de capitales




Figura 1 — El ciclo completo del blanqueo: de efectivo ilegal a dinero aparentemente legitimo

1.2 La regulacion que obliga a los bancos

Los bancos no hacen AML por voluntad propia. Estan obligados por ley, y las multas por incumplimiento son enormes. Algunos ejemplos reales:

Multas AML reales

ING: 775 millones de euros en 2018 por fallos sistematicos en su sistema AML. HSBC: 1.900 millones de dolares en 2012. BNP Paribas: 8.900 millones de dolares en 2014. Santander fue sancionado por el regulador irlandes en 2023 por deficiencias en controles AML. El negocio AML no desaparece en recesiones porque es obligacion legal, no inversion discrecional.

Regulacion	Que exige	Donde aplica
5a Directiva AML (UE)	Identificacion de beneficiarios reales, listas de riesgo, monitoreo de transacciones	Union Europea
FATF 40 Recomendaciones	Marco global de estandares AML/CFT	180+ paises
DORA (2025)	Resiliencia operacional digital, incluye sistemas de monitoreo	Union Europea
MiFID II	Transparencia en mercados financieros, prevencion de abusos	Union Europea
GDPR	Proteccion de datos en los procesos de compliance	Union Europea

1.3 Por que hay tan pocos analistas AML buenos

El gap de talento AML

El problema es que AML requiere simultaneamente dos tipos de conocimiento que normalmente no van juntos: conocimiento tecnico de datos (SQL, Python, dashboards) y conocimiento de dominio regulatorio (tipologias, directivas, procedimientos de escalacion). La mayoría de analistas tienen uno pero no el otro. AMLGuardian demuestra que tienes ambos.

2 Arquitectura del sistema

2.1 Vision general: como fluyen los datos

Antes de entrar en cada pieza, necesitas entender el flujo completo. Los datos entran por un extremo como CSV crudos y salen por el otro como alertas investigables, scores de riesgo y dashboards. En medio hay 7 capas que hacen cada una una cosa muy específica.




Figura 2 — Flujo de datos: de CSV crudo a alertas investigables y scores de riesgo

2.2 Cada pieza del puzzle explicada

Docker + Docker Compose

Docker es como una maquina virtual muy ligera. En lugar de instalar PostgreSQL, Airflow, Neo4j y todo lo demas en tu ordenador, Docker los ejecuta en contenedores aislados. Docker Compose levanta todos los contenedores juntos con un solo comando (`docker-compose up`). Esto es exactamente lo que hacen los equipos de datos en empresas reales.

PostgreSQL

La base de datos relacional donde vive practicamente todo. Tiene 5 schemas separados: raw (datos crudos), staging (datos limpios), features (indicadores por cuenta), alerts (alertas generadas) y ml (scores del modelo y metricas de grafo). PostgreSQL es el estandar en el 35% de aplicaciones financieras en produccion.

dbt (data build tool)

dbt es la herramienta que transforma los datos dentro de PostgreSQL usando SQL. En lugar de escribir un script Python que lea datos, los transforme y los guarde, con dbt escribes modelos SQL y el se encarga de ejecutarlos en orden, documentarlos y testearlos. Es el estandar de facto en analytics engineering moderno.

Airflow

El orquestador. Airflow define el orden en que se ejecutan las tareas del pipeline y lo hace automaticamente cada dia a las 2:00 AM. El DAG de AMLGuardian tiene 8 tareas en cadena.

Neo4j

Una base de datos de grafos. En lugar de tablas, Neo4j almacena nodos (cuentas) y relaciones (transacciones). Permite detectar patrones de red imposibles de ver con SQL: cuentas puente, comunidades sospechosas, caminos de layering.

XGBoost + SHAP

XGBoost aprende a identificar cuentas sospechosas a partir de sus características de comportamiento. SHAP explica por que el modelo asigno un score alto a cada cuenta. Sin SHAP, el modelo seria una caja negra inutilizable en entornos regulados.

2.3 Por que este stack y no otro

Stack de produccion tier 2-3

PostgreSQL domina en aplicaciones financieras (35%+ de cuota). dbt es el estandar de analytics engineering en 2025. Neo4j es usado en produccion por empresas AML como Fenargo, ThetaRay y los equipos de compliance de BNP Paribas y HSBC. Airflow orquesta pipelines en la practica totalidad de empresas tech de tamano medio. Este no es un stack academico: es lo que usan los equipos AML reales.

3 El dataset: los datos de partida

3.1 Que contiene el dataset de IBM

El dataset IBM AML (disponible en Kaggle) es un conjunto de transacciones bancarias sinteticas generado por IBM Research especificamente para entrenar y testear sistemas de deteccion AML. Es sintetico (inventado) pero replica fielmente los patrones de blanqueo real que estudian los equipos de compliance.

Datos del dataset

Mas de 10 millones de transacciones bancarias sinteticas. Cada transaccion esta etiquetada con `is_laundering`: 0 (legitima) o 1 (blanqueo). Incluye 5 tipologias AML incrustadas: fan-in, fan-out, ciclos, scatter-gather y cadenas. El ratio de transacciones de blanqueo es menor del 1% lo que lo hace realista y tecnicamente desafiante para el modelo ML.

3.2 Estructura de transacciones y cuentas

Columna	Tipo	Que representa
TransactionID	TEXT	Identificador unico de cada transaccion
Timestamp	TIMESTAMP	Cuando ocurrio la transaccion
SenderAccountID	TEXT	Cuenta que envia el dinero
ReceiverAccountID	TEXT	Cuenta que recibe el dinero
Amount	NUMERIC	Importe en la divisa original
Currency	TEXT	Divisa (USD, EUR, GBP, CHF...)
TransactionType	TEXT	Tipo: TRANSFER, CASH, PAYMENT...
IsLaundering	INTEGER	Etiqueta: 0=normal, 1=blanqueo (solo validacion)

3.3 Como se carga en el sistema (ingest.py)

El script `ingest.py` es la primera pieza del pipeline. Lee los CSV de Kaggle en trozos de 100.000 filas (chunking) para no colapsar la memoria RAM. Para cada trozo:

- Normaliza los nombres de columnas (camelCase a snake_case)
- Convierte todos los importes a EUR usando tipos de cambio hardcodedos (USD: 0.92, GBP: 1.17, CHF: 1.04)
- Convierte los timestamps a UTC
- Elimina duplicados y filas con datos criticos nulos

- Usa COPY de PostgreSQL (mucho mas rapido que INSERT para millones de filas)
- Registra cuantas filas se procesaron cada 100.000 en los logs de Airflow

El resultado son dos tablas en el schema raw de PostgreSQL: raw.transactions y raw.accounts, con un campo extra ingestion_timestamp para saber cuando se cargaron.

4 Deteccion de tipologias AML con SQL

Esta es la parte mas importante desde el punto de vista del analista AML. Cada tipologia representa un patron de comportamiento real. El sistema las detecta automaticamente con SQL dentro de dbt.


4.1 Smurfing: fragmentar para no ser visto

El smurfing (o structuring) es la practica de dividir grandes cantidades en muchas transacciones pequenas, justo por debajo del umbral que activa el reporte automatico (10.000 EUR en Europa). El nombre viene de los Pitufos: muchos pequenos hacen el trabajo de uno grande.

Ejemplo real

Una cuenta envia 14 transferencias entre EUR 4.200 y EUR 9.850 en 68 horas. Ninguna supera los 9.999 EUR individualmente, pero en conjunto mueven EUR 97.400. El sistema detecta esto calculando cuantas transacciones sub-umbral ha hecho cada cuenta en cualquier ventana de 72 horas.

Patron de smurfing: 12 pagos fraccionados bajo EUR 9.999 en 72 horas



ALERTA SMURFING detectada

12 transacciones sub-umbral en 72h
Total acumulado: EUR 97,950 — CRITICAL

Figura 3 — Smurfing: el blanqueador divide para no disparar los reportes automaticos

4.2 Fan-out: dispersion de fondos

El fan-out ocurre cuando una cuenta envia dinero a muchos destinos distintos en poco tiempo. Es como un hub de distribucion: recibe fondos concentrados y los dispersa rapidamente para dificultar el rastreo. Es tipico de cuentas mula que distribuyen fondos de origen ilicito.

Ejemplo real

Una cuenta envia dinero a 17 cuentas distintas en 19 horas. Los importes son similares (EUR 2.800-3.200 cada uno). El sistema detecta esto contando cuantos receptores distintos tuvo cada cuenta como emisor en cualquier ventana de 24 horas.

Fan-out: una cuenta distribuye fondos a 10+ beneficiarios en 24 horas

FAN-OUT detectado

10+ receptores distintos en 24h




Figura 4 — Fan-out: el dinero se dispersa rapidamente hacia multiples cuentas mula

4.3 Fan-in: consolidacion sospechosa

El opuesto del fan-out. Una cuenta recibe fondos de muchos origenes distintos en poco tiempo. Es el patron tipico de una cuenta de consolidacion o pooling, donde se acumulan fondos de multiples fuentes antes de moverlos en un solo bloque.

4.4 Circular: el dinero que vuelve

El patron circular detecta cuando los fondos completan un ciclo: A envia a B, B envia a C, C envia de vuelta a A, todo en menos de 7 dias. Simula actividad comercial real pero no tiene proposito economico legitimo.


La tecnica SQL: CTE recursiva

Para detectar ciclos se necesita una CTE recursiva. La idea es: empezamos en una cuenta, seguimos cada transferencia que hace, y comprobamos si alguno de los caminos nos lleva de vuelta al punto de inicio en 3 saltos. Es la parte tecnicamente mas sofisticada del proyecto.

4.5 Layering: cadena con comisiones

El layering detecta cadenas de transferencias donde cada pago retiene entre el 85% y el 99% del importe anterior. Esa reduccion consistente es la firma de una comision pagada a cada mula de la cadena.

Ciclo circular A→B→C→A en 7 días con step-down de importes (layering)



Reduccion ~7-8%
= comision de mula

Figura 5 — Circular + Layering: el dinero completa el ciclo y cada salto tiene una 'comision'

4.6 Alta exposicion geografica

Esta regla detecta cuentas que han realizado transacciones con paises de la lista FATF (paises con deficiencias en sus sistemas AML): Iran, Corea del Norte, Myanmar, Siria, Yemen, Haiti, Sudan del Sur, Nigeria, Venezuela, Camerun, Croacia, Kenia, Namibia, Vietnam y Sudafrica. No es automaticamente blanqueo, pero activa la obligacion de realizar diligencia debida reforzada.

Como se combinan las alertas

Una cuenta puede disparar varias alertas de distintas tipologias. Cuando una cuenta acumula 3 o mas alertas, o tiene al menos una alerta CRITICAL, pasa automaticamente a la tabla fct_sar_candidates: el listado de casos que el analista debe investigar para decidir si reportar al regulador (SEPBLAC en Espana).

5 El modelo de datos con dbt

5.1 Que es dbt y por que lo usamos

dbt permite escribir transformaciones de datos en SQL puro y ejecutarlas con buenas practicas de software: version control, tests automaticos, documentacion y linaje de datos.

Capas del modelo dbt: de datos crudos a alertas investigables




Figura 9 — Lineaje de datos en dbt: cada capa transforma y enriquece la anterior

5.2 Staging: limpiar los datos crudos

Los modelos de staging toman los datos crudos de raw y los normalizan. stg_transactions elimina duplicados usando DISTINCT ON de PostgreSQL, filtra filas con nulos en columnas críticas y normaliza texto a mayúsculas. stg_accounts hace lo mismo para las cuentas.

5.3 Feature mart: calcular indicadores por cuenta

fct_account_features es la tabla más importante para el modelo ML. Calcula 11 indicadores de comportamiento por cada cuenta usando todas sus transacciones:

Feature	Que mide	Por que es relevante para AML
total_sent / total_received	Importe total movido	Volumen inusualmente alto indica riesgo
n_transactions	Numero total de operaciones	Alta frecuencia puede indicar automatizacion
avg_amount_sent	Importe medio de envios	Importes sistemáticamente similares = smurfing
stddev_amount_sent	Variabilidad de los importes	Poca variacion = patron automatizado
n_unique_counterparts	Cuentas distintas con las que opera	Muchas = fan-out / fan-in
n_countries_transacted	Países distintos en sus operaciones	Alta exposicion geografica

ratio_night_transactions	% de ops entre 00:00 y 06:00	Actividad nocturna = automatizacion sospechosa
max_single_transaction	Mayor importe individual	Transacciones muy grandes son red flag
velocity_7d	Importe enviado en los ultimos 7 dias	Aceleracion reciente = actividad inusual

5.5 SAR candidates: casos para escalar

SAR son las siglas de Suspicious Activity Report. La tabla fct_sar_candidates filtra automaticamente las cuentas que tienen 3 o mas alertas acumuladas, o al menos una alerta de severidad CRITICAL. Estas son las cuentas que el analista debe investigar a fondo.

5.6 Tests de calidad de datos

dbt permite escribir tests que verifican la integridad de los datos. AMLGuardian tiene mas de 50 tests en schema.yml y ficheros SQL de test: not_null, unique, accepted_values, relationships y tests de logica de negocio custom.

6.1 Por que los grafos revelan lo que SQL no ve

Con SQL puedes ver que la cuenta A le mando dinero a B. Pero no puedes ver facilmente que A esta conectada indirectamente con C a traves de 4 intermediarios, y que esa cadena forma parte de una comunidad de 23 cuentas que todas se transfieren dinero entre si ciclicamente. Para eso necesitas un grafo.

La metafora del grafo

Imagina un mapa de metro. Las estaciones son cuentas bancarias. Las lineas entre estaciones son transacciones. SQL te dice si dos estaciones concretas estan conectadas. Neo4j te dice cual es la estacion mas importante de toda la red, que grupos de estaciones forman una misma linea, y cual es el camino mas corto entre cualquier par de estaciones.

Red de transacciones: 3 comunidades detectadas por Louvain. Nodos rojos = PageRank alto




Figura 6 — Neo4j GDS detecta comunidades sospechosas y cuentas centrales (posibles mulas)

6.2 Como se construye el grafo

El script `load_graph.py` lee las tablas de staging de PostgreSQL y las carga en Neo4j. Crea nodos Account y relaciones TRANSFERRED con todos sus atributos (importe, divisa, timestamp). Lo hace en lotes de 10.000 registros para no saturar la memoria.

6.3 PageRank: quien es el nodo central

PageRank es el algoritmo que Google usa para determinar que paginas web son mas importantes. En AMLGuardian lo usamos para detectar que cuentas son mas centrales en la red de transacciones. Una

cuenta con PageRank alto que además tiene alertas de fan-in o fan-out es un indicador muy fuerte de cuenta mula central.

6.4 Louvain: detección de comunidades

El algoritmo Louvain agrupa automáticamente las cuentas en comunidades según la densidad de sus conexiones. Si dentro de una comunidad hay una cuenta con alerta de blanqueo, las demás cuentas de esa comunidad son candidatas a investigación por proximidad.

Los resultados se escriben de vuelta en PostgreSQL (ml.graph_account_metrics) para que el analista pueda consultarlos desde pgAdmin o Power BI junto con el resto de datos.

7 El modelo de machine learning

7.1 Para que sirve el scoring ML

Las reglas SQL son determinísticas: o cumples la condicion o no la cumples. El modelo ML anade una capa probabilística: aprende de los patrones del dataset y asigna a cada cuenta un score de riesgo entre 0 y 100. Una cuenta puede no disparar ninguna alerta de regla pero tener un score ML de 85 porque su comportamiento global es estadísticamente anormal.

7.3 El problema del desbalance y SMOTE

El problema del desbalance

En el dataset, menos del 1% de las cuentas estan involucradas en blanqueo. Si entrenamos un modelo con estos datos tal cual, aprendera a decir 'normal' para todo porque acertara el 99% de las veces. Eso es inutil para AML. SMOTE genera ejemplos sinteticos adicionales de la clase minoritaria hasta equilibrar la proporcion.

Pipeline ML: features comportamentales → XGBoost → score 0-100 → explicacion SHAP por cuenta




Figura 7 — El modelo ML asigna un score de riesgo a cada cuenta y SHAP explica el motivo

7.4 XGBoost vs LightGBM vs Isolation Forest

Modelo	Tipo	Como funciona	Cuando gana
XGBoost	Supervisado (con etiquetas)	Arboles de decision en cascada. Cada arbol se entrena con los errores de los anteriores.	Dataset grande, datos de balanceo.
LightGBM	Supervisado (con etiquetas)	Similar a XGBoost pero mas rapido. Usa Gradient Boosting.	Dataset grande, datos de balanceo.

Isolation Forest	No supervisado (sin etiquetas)	Aísla puntos anomalos aleatoriamente.	Como si fueras cuentas de robo.
------------------	-----------------------------------	---------------------------------------	---------------------------------

Como si fueras cuentas de robo. Detecta anomalas.

7.5 SHAP: por que el modelo toma cada decision

SHAP (SHapley Additive exPlanations) calcula cuanto contribuyo cada feature al score final. Si una cuenta tiene score 91, SHAP te dice: 35 puntos vinieron de ratio_night_transactions, 28 de n_unique_counterparts, 18 de velocity_7d. En el sector financiero, el regulador puede exigirte que expliques por que reportaste una cuenta. Con SHAP puedes hacerlo.

Por que SHAP es critico para AML

En el sector financiero, el regulador puede exigirte que expliques por que cerraste una cuenta o hiciste un SAR. 'El modelo dijo que si' no es una respuesta valida. Con SHAP puedes decir: 'La cuenta disparo el modelo principalmente por su ratio de transacciones nocturnas (0.71 frente a media de 0.12) y por haber operado con 23 paises distintos en 30 dias.' Eso si es una justificacion regulatoria.

8 Orquestacion con Airflow

8.1 Que es un DAG y como funciona

DAG significa Directed Acyclic Graph: un grafo dirigido sin ciclos. En Airflow, un DAG es un fichero Python que define que tareas existen y en que orden deben ejecutarse. Dirigido significa que las flechas van en una sola direccion (tarea A a tarea B). Aciclico significa que no hay bucles. Cada tarea puede ser un script Python, un comando bash, una query SQL, lo que sea.

DAG de Airflow: 8 tareas en cadena, ejecutadas en orden cada noche




Figura 8 — El DAG de Airflow garantiza el orden correcto de ejecucion del pipeline

8.2 El pipeline de AMLGuardian paso a paso

Tarea	Herramienta	Que hace	Depende de
1. ingest_raw_data	BashOperator ingest.py	Lee los CSV y carga en PostgreSQL raw_data	Primera tarea
2. run_dbt_staging	BashOperator dbt run	Ejecuta stg_transactions y stg_accounts	ingest_raw_data
3. run_dbt_features	BashOperator dbt run	Calcula fct_account_features	run_dbt_staging
4. run_dbt_alerts	BashOperator dbt run	Genera todas las alertas y SAR candidates	run_dbt_features
5. run_dbt_tests	BashOperator dbt test	Valida 50+ tests de calidad + genera docs	run_dbt_alerts
6. load_neo4j_graph	BashOperator load_graph.py	Carga el grafo, ejecuta PageRank y Louvain	run_dbt_tests
7. train_ml_model	BashOperator train_model.py	Entrena XGBoost, genera SHAP, escribe logs	load_neo4j_graph
8. notify_completion	PythonOperator	Consulta conteos y registra resumen en logs	train_ml_model

Por que el orden importa

Si ejecutaras `dbt_alerts` antes que `dbt_features`, fallaria porque `alerts` depende de la tabla `features.fct_account_features` que aun no existe. Si ejecutaras `load_neo4j` antes que `dbt_staging`, Neo4j intentaria leer tablas vacias. Airflow garantiza el orden correcto y, si una tarea falla, para el pipeline ahi y reintenta automaticamente.

9 Tu trabajo como analista

Todo lo anterior es la infraestructura. Lo que sigue es el trabajo que hace el analista AML: la parte que demuestra que entiendes el negocio, no solo las herramientas.

Flujo de trabajo del analista AML: de alerta automatica a reporte SAR formal




Figura 10 — El analista AML transforma alertas del sistema en decisiones regulatorias documentadas

9.1 Las investigation queries SQL

Fichero SQL	Para que sirve
smurfing_deep_dive.sql	Reconstruye la timeline completa de una cuenta de smurfing: todas las transacciones sub-umbrales
fan_out_investigation.sql	Muestra a donde fue el dinero de una cuenta fan-out: cada beneficiario, pais, importe y ranking
circular_flows.sql	Reconstruye el ciclo completo A→B→C→A con los 3 transaction IDs, timestamps y importe total
high_risk_accounts.sql	Prioriza cuentas que combinan multiples tipologias de alerta con score ML alto (los casos mas u
sar_candidates.sql	Pack completo de escalacion: cuenta + alertas + score ML + metricas Neo4j + estadisticas de tr
geographic_analysis.sql	Mapa de corredores de pago por pais, marcando los que cruzan jurisdicciones de riesgo FATF

9.2 El dashboard Power BI

Power BI se conecta directamente a PostgreSQL y lee las tablas que dbt genero. El dashboard tiene 5 paginas orientadas a distintas necesidades del equipo de compliance: Executive Overview, Alert Queue, Account Profile, SAR Cases y Tipologias.

9.3 Documentacion de casos SAR

La parte mas diferenciadora del proyecto. Tienes que documentar 3 casos reales de investigacion usando los datos del dataset, siguiendo el formato de un Suspicious Activity Report real (estructura del SEPBLAC): cuenta, periodo, importe, tipologia activada, evidencia concreta, hallazgo y recomendacion.

Estructura de cada caso SAR

1. CUENTA: ID y datos basicos (pais, tipo). 2. PERIODO: Fechas de la actividad sospechosa. 3. IMPORTE: Cantidad total involucrada en EUR. 4. TIPOLOGIA: Que alerta genero el sistema. 5. EVIDENCIA: Metricas concretas del SQL y del grafo. 6. HALLAZGO: En 2 frases, que indica este patron. 7. RECOMENDACION: SAR formal / EDD / monitoreo / archivar.

10 Como explicarlo en entrevistas

El pitch de 30 segundos

Lo que dices cuando te pregunten por tu proyecto principal

Construi un sistema end-to-end de deteccion de blanqueo de capitales sobre 10 millones de transacciones sinteticas del dataset de IBM. Detecta 6 tipologias AML reales (smurfing, fan-out, fan-in, ciclos, layering y exposicion geografica) usando SQL dentro de dbt sobre PostgreSQL. Complemento la deteccion basada en reglas con analisis de redes en Neo4j (PageRank y deteccion de comunidades) y con un modelo XGBoost con SHAP para scoring de riesgo explicable. Todo orquestado con Airflow y containerizado con Docker. Y la parte analitica la hice como lo hace un analista AML real: investigation queries, dashboard en Power BI y documentacion de casos SAR siguiendo el formato del SEPBLAC.

Preguntas frecuentes y como responderlas

P: Por que PostgreSQL y no otra base de datos?

R: PostgreSQL tiene mas del 35% de cuota en aplicaciones financieras porque es ACID-compliant, tiene soporte nativo para CTEs recursivas (que uso para detectar ciclos) y window functions avanzadas. DuckDB es genial para analisis local pero ningun banco lo usa en produccion.

P: Para que usas Neo4j si ya tienes SQL?

R: SQL ve relaciones directas bien. Pero para ver redes de transacciones, quien es el nodo mas central de 200.000 cuentas, o que grupos se transfieren dinero entre si formando comunidades sospechosas, necesitas un grafo. Neo4j con GDS hace en segundos lo que seria imposible con SQL puro.

P: Por que XGBoost y no una red neuronal?

R: XGBoost es interpretable con SHAP, entrena rapido en datos tabulares y es el estandar en competiciones de datos financieros. Las redes neuronales son cajas negras y eso es un problema en AML porque el regulador puede pedirte que justifiques tus decisiones.

P: Como garantizas la calidad de los datos?

R: Con mas de 50 tests de dbt distribuidos en schema.yml y ficheros SQL custom: tests de unicidad en alert_ids, integridad referencial entre alertas y cuentas, y tests de logica de negocio como que el ratio nocturno este siempre entre 0 y 1.

P: Que harias diferente en produccion real?

R: Externalizaria las tasas de cambio a una tabla de referencia actualizada via API. La lista de paises de riesgo FATF se actualizaria automaticamente desde su web. Aniadaria feedback de los analistas para reentrenar el modelo con SAR confirmados. Usaria dbt incremental en lugar de full-refresh.

Tu diferenciador real

Lo que ningun otro junior tiene

La combinacion de Neo4j (muy pocos analistas junior lo dominan) + CTEs recursivas para deteccion de ciclos (tecnicamente exigente) + SHAP para explicabilidad (critico en entornos regulados) + documentacion en formato SAR real (demuestra mentalidad de analista, no de programador) es una combinacion que no vera en ningun otro CV junior el reclutador de Excelia, Fenargo, Stripe Risk o cualquier banco con equipo AML analytics.